

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
НОВОСИБИРСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ
УНИВЕРСИТЕТ

Кафедра ВТ

Расчетно-графическая работа

По дисциплине

«Представление знаний в системах искусственного интеллекта»

**Разработка web-интерфейса для моделей прогнозирования
цены на алмазы**

Факультет: АВТФ

Группа: АПИМ-25

Выполнил: Бадагов А.В. Клименко К.В.

Преподаватель: Яковина И. Н.

Отметка о защите:

Новосибирск 2025

Оглавление

Цель	3
Задачи	3
Используемые программные инструменты.....	3
Ход работы.....	4
1 Подготовка датасета	4
2 Нормализация данных и формирование обучающих и проверочные данные	4
3 Модель линейной регрессии	6
4 Модель нейронной сети.....	7
5 Сохранение модели и формирование JSON файла.....	9
6 Разработка web интерфейса	12
7 Проверка полученного результата	17
Заключение	20
Приложение А	21
Приложение Б.....	22

Цель

Знакомство элементами технологии создания баз знаний интеллектуальных систем.

Задачи

- Освоение способа сохранения и загрузки обученных моделей машинного обучения.
- Разработка интерфейса доступа к сохраненным моделям.
- Организация произвольных запросов с использованием разработанного интерфейса.

Используемые программные инструменты

- Язык программирования: python.
- Реализация алгоритмов машинного обучения: tensorflow, sklearn.
- Сериализация/десериализация: json, pickle, tensorflow.
- Web-интерфейс: streamlit.

Ход работы

1 Подготовка датасета

Проведём анализ и проверку дата сета рисунок 1.1 на наличие пропусков см.рисунок 1.2.

```
Размер таблицы (47327, 10)
  carat  cut  color  clarity  depth  table  price    x    y    z
0   0.23   5     6         2   61.5   55.0  326.0  3.95  3.98  2.43
1   0.21   4     6         3   59.8   61.0  326.0  3.89  3.84  2.31
2   0.29   4     2         4   62.4   58.0  334.0  4.20  4.23  2.63
3   0.31   2     1         2   63.3   58.0  335.0  4.34  4.35  2.75
4   0.24   3     1         6   62.8   57.0  336.0  3.94  3.96  2.48
```

Рисунок 1.1 – Часть исходного датасета

```
Размер таблицы (47327, 10)
carat      0
cut        0
color      0
clarity    0
depth      0
table      0
price      0
x          0
y          0
z          0
dtype: int64
```

Рисунок 1.2 – Количество пустых значений в исходных данных

```
['carat', 'cut', 'color', 'clarity', 'depth', 'table', 'x', 'y', 'z']
['price']
Размер таблицы (47327, 9)
Размер таблицы (47327, 1)
```

Рисунок 1.3 – Объявление названий целевых (target) и независимой (features)

2 Нормализация данных и формирование обучающих и проверочные данные

Нормализация - приведения значений к диапазону от 0.0 до 1.0, для этого определяется минимальное значения и максимальное, где минимальному соответствует 0 максимальному соответственно 1.

В библиотеке `sklearn`, для выполнения процедуры нормализации, присутствует класс `sklearn.preprocessing.MinMaxScaler`, который содержит методы:

- *MinMaxScaler.fit(df)* - вычисление значений минимального, максимального значений и диапазона;
- *MinMaxScaler.transform(df)* - прямого преобразования из истинного значения к приведенному.

Листинг 1 нормализация данных

```

scalerNormX = MinMaxScaler()
scalerNormX.fit(dfX)
dfXNorm = pd.DataFrame (data = scalerNormX.transform(dfX), columns = dfX.columns,
index = dfX.index)
print("Размер таблицы", dfXNorm.shape)

scalerNormY = MinMaxScaler()
scalerNormY.fit(dfY)
dfYNorm = pd.DataFrame (data = scalerNormY.transform(dfY), columns = dfY.columns,
index = dfY.index)
print("Размер таблицы", dfYNorm.shape)

```

```

Размер таблицы (47327, 9)
Размер таблицы (47327, 1)

```

	carat	cut	color	clarity	depth	table	x	y	\
0	0.016667	1.00	0.833333	0.142857	0.457627	0.260870	0.048352	0.065359	
1	0.005556	0.75	0.833333	0.285714	0.169492	0.782609	0.035165	0.034858	
2	0.050000	0.75	0.166667	0.428571	0.610169	0.521739	0.103297	0.119826	
3	0.061111	0.25	0.000000	0.142857	0.762712	0.521739	0.134066	0.145969	
4	0.022222	0.50	0.000000	0.714286	0.677966	0.434783	0.046154	0.061002	

Рисунок 2.1 – Представление данных в нормализованном виде

Листинг 2 обучающую и проверочную части

```

x_train,x_test, y_train, y_test = train_test_split(
    dfX,
    dfY,
    random_state=42,
    test_size=0.2
)

x_norm_train,x_norm_test, y_norm_train, y_norm_test = train_test_split(
    dfXNorm,
    dfYNorm,
    random_state=42,
    test_size=0.2
)

```

В листинге программы 2 *train_test_split()* осуществляет деление данных случайным образом.

3 Модель линейной регрессии

Листинг 3 функции модели линейной регрессии

```
def train_linear_model(x_tr, y_tr, x_t, y_t):  
    model = linear_model.LinearRegression()  
    model.fit(x_tr, y_tr)  
  
    y_pred = model.predict(x_t)  
  
    mse = mean_squared_error(y_t, y_pred)  
    rmse = mse ** 0.5  
    r2 = r2_score(y_t, y_pred)  
  
    return model, y_pred, r2, rmse
```

`linear_model.LinearRegression()` и `model.fit(x_tr, y_tr)` – данные команды отвечают за создание модели линейно регрессии и процесс обучения соответственно.

`model.predict(x_t)` – команда отвечает за прогнозирование.

Так же определим метки оценки качества модели:

- MSE - Mean Squared Error (Средняя квадратичная ошибка), показывает средний квадрат ошибок;
- RMSE - Root Mean Squared Error (Среднеквадратичная ошибка), показывает типичное отклонение величины ошибки;
- R^2 - R-squared (Коэффициент детерминации), показывает на сколько сильно ошибка отличается от среднего значения.

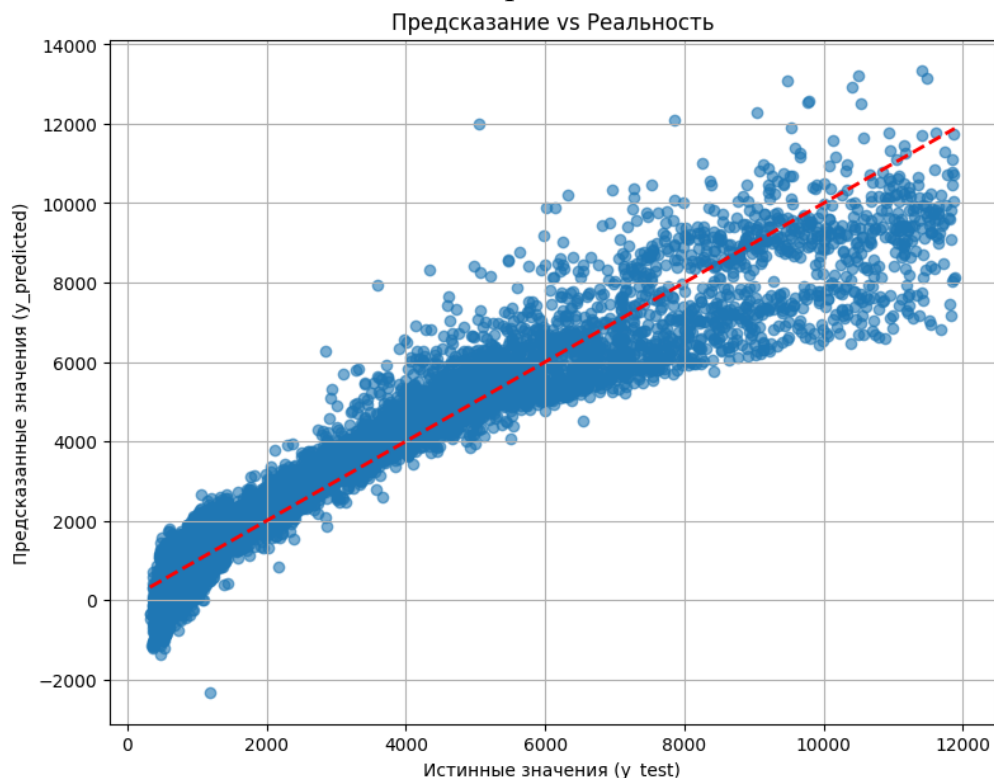


Рисунок 3.1 – Сравнение спрогнозированных значений с эталонными

В результате прогнозирования значений с помощью линейной регрессии коэффициент детерминации имеет значение $R^2 = 0.9152$, а среднеквадратичная ошибка $RMSE = 798,569\$$.

4 Модель нейронной сети

Листинг 4 функция модели нейронной сети

```
def compile_model(add_layers:bool, feature):
    model = tf.keras.models.Sequential()

    # Входной слой
    model.add(tf.keras.layers.Input(shape=(len(feature),)))

    # Скрытые слои
    model.add(tf.keras.layers.Dense(64, activation='relu'))
    model.add(tf.keras.layers.Dense(32, activation='relu'))
    model.add(tf.keras.layers.Dense(1, activation='linear'))

    # Функции потерь и оптимизации
    fLoss=tf.keras.losses.MeanSquaredError()
    fOptimizer=tf.keras.optimizers.Adam(learning_rate=0.02)
    fMetricList = [tf.keras.losses.MeanSquaredError(),
tf.keras.losses.MeanAbsoluteError()]

    model.compile(
        loss=fLoss,
        optimizer=fOptimizer,
        metrics=fMetricList
    )
    return model

def fit_model_and_print_results(model, feature:list):
    totalHistoryLossTrain=[] # Вспомогательный список для хранения полной истории
обучения
    totalHistoryLossTest=[] # Вспомогательный список для хранения полной истории
обучения
    history = model.fit(
        x_norm_train[feature],
        y_norm_train,
        validation_data=(
            x_norm_test[feature],
            y_norm_test
        ),
        epochs=20,
        batch_size=64,
        verbose=0
    )
    y_pred = model.predict(x_norm_test[feature])

    r2 = r2_score(y_norm_test, y_pred)
    mse = mean_squared_error(y_norm_test, y_pred)
    rmse = mse ** 0.5

    return y_pred, r2, rmse, history
```

На вход нейронной сети подаётся 9 целевых параметра, которые потом являются входными параметрами для скрытого слоя состоящего из 64 нейронов с функцией активации *relu*, см. рисунок 4.1.

```
Вид ф-ии активации слоя: relu
Кол-во ВХодов  слоя: 9
Кол-во ВЫходов слоя: 64
Кол-во нейронов слоя:   64
```

Рисунок 4.1 – Первый скрытый слой модели нейронной сети

Параметры второго скрытого слоя приведены на рисунке 4.2. он состоит из 32 нейронов с функцией активации *relu*.

```
Вид ф-ии активации слоя: relu
Кол-во ВХодов  слоя: 64
Кол-во ВЫходов слоя: 32
Кол-во нейронов слоя:   32
```

Рисунок 4.2 – Второй скрытый слой модели нейронной сети

На выходной слой модели состоит из 1 нейрона, значения цены и имеет функцию активации *linear*, см. рисунок 4.3.

```
Вид ф-ии активации слоя: linear
Кол-во ВХодов  слоя: 32
Кол-во ВЫходов слоя: 1
Кол-во нейронов слоя:   1
```

Рисунок 4.3 – Выходной слой модели

Функция оптимизации и оценки потерь используется *Adam* и *MSE* соответственно.

В результате прогнозирования значений с помощью модели нейронной сети коэффициент детерминации имеет значение $R^2 = 0.972$, а среднеквадратичная ошибка $RMSE = 0.0394$ в нормализованном виде.

5 Сохранение модели и формирование JSON файла

Листинг 5 формирование JSON для модели линейной регрессии

```
def build_model_info_linear(
    model,
    features,
    target_names,
    r2,
    rmse,
    requires_norm: bool = False
):
    # тип модели
    model_type = type(model).__name__
    params = model.get_params()

    # коэффициенты и свободный член

    coef = np.asarray(model.coef_)
    intercept = np.asarray(model.intercept_)
    coef_list = coef.tolist()
    intercept_list = intercept.tolist()

    coef_by_feature = {}
    for i, tname in enumerate(target_names):
        coef_by_feature[tname] = {
            feat: float(w) for feat, w in zip(features, coef_list[i])
        }

    model_info = {
        "Тип модели": model_type,
        "Названия входных признаков": list(features),
        "Названия выходных признаков": list(target_names),
        "R2": float(r2),
        "RMSE": float(rmse),
        "Коэффициенты по признакам": coef_by_feature,
        "Свободный член": intercept_list
    }
    return model_info
```

Функция `build_model_info_linear` формирует структурированное описание модели линейной регрессии. В цикле `for feat, w in zip(features, coef_list[i])` осуществляется сопоставление полученного веса с его признаком, `zip`.

Листинг 6 сохранение модели линейной регрессии в JSON

```
with open("m1_info.json", "w", encoding="utf-8") as f:
    js.dump(model_info_m1, f, ensure_ascii=False, indent=2)

with open("linear_model.pkl", "wb") as f:
    pickle.dump(model_m1, f)
```

Листинг 7 формирование JSON для модели нейронной сети

```
def build_model_info_from_keras(model, features, target_names, r2, rmse,
requires_norm: bool):
    # Описание структуры
    layer_desc = []
    for layer in model.layers:
        cfg = layer.get_config()
        layer_type = layer.__class__.__name__

        if isinstance(layer, tf.keras.layers.Dense):
            units = cfg.get("units")
            activation = cfg.get("activation")
            layer_desc.append(f"{layer_type}(units={units},
activation={activation})")
        else:
            layer_desc.append(layer_type)

    structure_str = " -> ".join(layer_desc)

    # Функция потерь
    if isinstance(model.loss, str):
        loss_name = model.loss
    else:
        loss_name = model.loss.__class__.__name__

    # Оптимизатор и его learning rate
    opt = model.optimizer
    opt_name = opt.__class__.__name__
    try:
        lr_value = float(tf.keras.backend.get_value(opt.learning_rate))
    except Exception:
        lr_value = None

    model_info = {
        "Тип модели": type(model).__name__,
        "Нормализованные данные": bool(requires_norm),
        "Названия входных признаков": list(features),
        "Названия выходных признаков": list(target_names),
        "R2": float(r2),
        "RMSE": float(rmse),
        "Структура": structure_str,
        "Функция потерь": loss_name,
        "Оптимизатор": f"{opt_name}(learning_rate={lr_value})"
    }
    return model_info
```

Функция *build_model_info_from_keras()* формирует структурированное описание модели нейронной сети. В цикл *for layer in model.layers:* извлекается тип слоя и его конфигурация. *if isinstance(layer, tf.keras.layers.Dense):* условие по которому определяются тип слоя и выписываются его параметры. *float(tf.keras.backend.get_value(opt.learning_rate))* данная команда определяет заданные параметры в оптимизаторе, в случае их отсутствия выводит *None*, *except Exception: lr_value = None*

Листинг 8 сохранение модели, шкалеров и JSON

```
model_m2.save('keras_model.h5')
with open("scaler_x.pkl", "wb") as f:
    pickle.dump(scalerNormX, f)

with open("scaler_y.pkl", "wb") as f:
    pickle.dump(scalerNormY, f)

with open("m2_info.json", "w", encoding="utf-8") as f:
    js.dump(model_info_m2, f, ensure_ascii=False, indent=2)
```




Рисунок 5.1 – сохранённые форматы моделей, шкалеров и JSON

```
{
  "Тип модели": "LinearRegression",
  "Названия входных признаков": [
    "carat",
    "cut",
    "color",
    "clarity",
    "depth",
    "table",
    "x",
    "y",
    "z",
  ],
  "Названия выходных признаков": [
    "price",
  ],
  "R2": 0.9151602765339839,
  "RMSE": 798.5693271182033,
  "Коэффициенты по признакам": {
    price: {
      carat: 10513.862029486445,
      cut: 59.70354835550495,
      color: 244.48529475706488,
      clarity: 376.3449362625993,
      depth: 7.856496977681996,
      table: -22.211148847180112,
      x: -1294.8241636591206,
      y: 972.5681219445239,
      z: -1176.118075554485,
    },
  },
  "Свободный член": [
    -624.2015349430158,
  ],
}
```

Рисунок 5.2 – JSON модели линейной регрессии

```
{
  "Тип модели": "Sequential",
  "Нормализованные данные": true,
  "Названия входных признаков": [
    "carat",
    "cut",
    "color",
    "clarity",
    "depth",
    "table",
    "x",
    "y",
    "z",
  ],
  "Названия выходных признаков": [
    "price",
  ],
  "R2: 0.9759392142295837",
  "RMSE: 0.036781987562052545",
  "Структура: \"Dense(units=64, activation=relu) -> Dense(units=32, activation=relu) -> Dense(units=1, activation=linear)\",
  "Функция потерь": \"MeanSquaredError\",
  "Оптимизатор: \"Adam(learning_rate=0.019999999552965164)\",
}
```

Рисунок 5.3 – JSON модели нейронной сети

6 Разработка web интерфейса

Разработанная программа по прогнозу цены за алмаз имеет модульную архитектуру, в работе было принято решение отделить внутреннюю логику от представления. Первым модулем является сервисный, он представлен в приложении А. Модуль графического интерфейса программы представлен в приложении Б.

Листинг 9 функция проверки на наличие модели и шкалеров

```
def init_models_and_scalers():
    if 'models_loaded' not in st.session_state:
        try:
            linear_model, keras_model, scaler_x, scaler_y =
load_models_and_scalers()
            st.session_state.update({
                'linear_model': linear_model,
                'keras_model': keras_model,
                'scaler_x': scaler_x,
                'scaler_y': scaler_y,
                'models_loaded': True
            })
            st.toast("✔ Модели и шкалёры успешно загружены.")
        except Exception as e:
            st.toast(f"✗ Ошибка загрузки: {e}")
            st.stop()
```

Функция `init_models_and_scalers()` однократно проводит проверку на уже загруженные модели и объекты шкалеры. Условие `if 'models_loaded' not in st.session_state:` как раз используется для проверки на ранее уже загруженные файлы, в случае неудачи выдает ошибку.

Листинг 10 функция загрузки файлов модели и шкалеров

```
def load_models_and_scalers():
    with open(FOLDER + 'linear_model.pkl', 'rb') as f:
        lin_model = pickle.load(f)
```

```

ker_model = load_model(FOLDER + 'keras_model.h5', compile=False)

with open(FOLDER + 'scaler_x.pkl', 'rb') as f:
    scal_x = pickle.load(f)

with open(FOLDER + 'scaler_y.pkl', 'rb') as f:
    scal_y = pickle.load(f)

return lin_model, ker_model, scal_x, scal_y

```

Команда *with open()* в своей конструкции указывает путь к файлу который необходимо открыть, команда *pickle.load(f)* обеспечивает считывание файла.

Листинг 11 настройка интерфейса

```

notification_shown = False

st.set_page_config(page_title="Прогнозирование цены бриллианта", layout="wide")
st.title("💎 Прогнозирование цены бриллианта")

service.init_models_and_scalers()

linear_model = st.session_state.linear_model
keras_model = st.session_state.keras_model
scaler_x.MinMaxScaler = st.session_state.scaler_x
scaler_y.MinMaxScaler = st.session_state.scaler_y


input_column, margin, output_column = st.columns([2, 0.25, 3])

```

st.set_page_config –устанавливать название страницы.

st.title – заголовок страницы.

input_column, margin, output_column = st.columns([2, 0.25, 3]) – разделение экрана на рабочие зоны.



Характеристика алмаза

Рисунок 6.1 – Результат части программы листинг 11

Листинг 12 ввод характеристик, левая рабочая зона

```

st.header("Характеристика алмаза")

carat = st.slider("Караты", min_value=0.2, max_value=2.0, value=1.1, step=0.01)
cut = st.selectbox("Качество огранки", ["Fair", "Good", "Very Good", "Premium", "Ideal"], index=2)
color = st.radio("Цвет", ['J', 'I', 'H', 'G', 'F', 'E', 'D'], index=3, horizontal=True)
clarity = st.selectbox("Чистота", ['I1', 'SI2', 'SI1', 'VS2', 'VS1', 'VVS2', 'VVS1', 'IF'], index=4)

```

```

depth = st.slider("Глубина", min_value=58.8, max_value=64.7, value=61.8, step=0.1)
table = st.slider("Плоская грань", min_value=52.0, max_value=63.5, value=57.8,
step=0.1)
x = st.slider("Длина", min_value=3.73, max_value=8.28, value=6.0, step=0.01)
y = st.slider("Высота", min_value=3.68, max_value=8.27, value=5.98, step=0.01)
z = st.slider("Ширина", min_value=1.41, max_value=5.3, value=3.36, step=0.01)

```

st.header – заголовок рабочей зоны.

st.slider – слайдер, ползунок изменяет значения параметра, указывается наименование, максимальное и минимальное значение, значение по умолчанию и шаг изменения.

st.selectbox – выпадающий список, index присваивается значение по умолчанию.

st.radio – выбор одного значения из набора.

Листинг 13 отрисовка кнопки прогнозирования

```

### Кнопка предсказания
st.markdown("""
<style>
    button[kind="primary"] {
        background: linear-gradient(135deg, #8b5cf6, #7c3aed);
        color: white;
        border-radius: 12px;
        padding: 16px 28px;
        font-size: 20px;
        font-weight: 600;
        box-shadow: 0 4px 14px rgba(139, 92, 246, 0.3);
    }
    button[kind="primary"]:hover {
        transform: translateY(-2px);
        box-shadow: 0 6px 20px rgba(139, 92, 246, 0.4);
    }
</style>
""", unsafe_allow_html=True)

clicked = st.button("Предсказать", type="primary", use_container_width=True)

```

Внутри *st.markdown* задаются параметры кнопки: градиентный фон, белый текст, скругление, размер/жирность шрифта и тень.

st.button – кнопка без фиксации, в момент нажатия выдает значение *True*.

Листинг 14 создание таблицы исходных значений

```

### Таблица исходных X
st.markdown(
    "<h2 style='text-align: center; color: #2d3748; font-size: 30px';>исходные X</h2>",
    unsafe_allow_html=True
)
df_raw_x = pd.DataFrame(input_data)
st.dataframe(
    df_raw_x,
    hide_index=True,
    use_container_width=True,
    column_config={

```

```

"carat": st.column_config.NumberColumn("carat", format="%.2f"),
"depth": st.column_config.NumberColumn("depth", format="%.1f"),
"table": st.column_config.NumberColumn("table", format="%.1f"),
"x": st.column_config.NumberColumn("x", format="%.2f"),
"y": st.column_config.NumberColumn("y", format="%.2f"),
"z": st.column_config.NumberColumn("z", format="%.2f"),
}
)

```

Внутри *st.markdown* задаются параметры таблицы, выравнивание, размер шрифт.

pd.DataFrame(input_data) – создание датафрейма.

st.dataframe – отображение введенных значений из левой рабочей зоны в таблицу.

Характеристика алмаза

Караты 1.10

Качество огранки

Very Good ▼

Цвет

☐ J ☐ I ☐ H ☒ G ☐ F ☐ E ☐ D

Чистота

VS1 ▼

Глубина 63.40

Плоская грань 56.00

Длина 7.72

Высота 4.28

Ширина 4.40

Предсказать

Рисунок 6.2 – Результат части программы листинг 12 и 13, левая рабочая зона

исходные X

carat	cut	color	clarity	depth	table	x	y	z
1.10	Very Good	G	VS1	63.4	56.0	7.72	4.28	4.40

нормализованные X

carat	cut	color	clarity	depth	table	x	y	z
0.5	0.5	0.5	0.5714	0.7797	0.3478	0.8769	0.1307	0.7686

Рисунок 6.3 – Результат части программы листинг 14 и 15

Листинг 15 создание таблицы нормализованных значений

```

### Таблица нормализованных X
df_x = service.get_prepared_df_x(df_raw_x)
st.markdown(
    "<h2 style='text-align: center; color: #2d3748; font-size: 30px';>нормализованные X</h2>",
    unsafe_allow_html=True
)
columns = ['carat', 'cut', 'color', 'clarity', 'depth', 'table', 'x', 'y', 'z']
df_norm_x = pd.DataFrame (data = scaler_x.transform(df_x), columns = df_x.columns, index = df_x.index)
st.dataframe(df_norm_x, hide_index=True, use_container_width=True)

```

service.get_prepared_df_x(df_raw_x) – запуск функции преобразования признаков в численный вид.

pd.DataFrame (data = scaler_x.transform(df_x), columns = df_x.columns, index = df_x.index) – формирование датафрейма с нормализованными данными.

st.dataframe – отображение нормализованных значений.

Листинг 16 результаты расчёта

```

if clicked:
    with col_linear:
        st.header("Линейная регрессия")
        st.write("***R²=0.9163**")
        st.write("***RMSE=797.49**")

        st.subheader("предсказанный Y")
        pred_price_linear = max(0, linear_model.predict(df_x).item())

        st.metric(label="price", value=f"${pred_price_linear:,.2f}")

    with col_neural:
        st.header("Нейронная сеть")
        st.write("***R²=0.974**")
        st.write("***RMSE=0.0353**")

        st.subheader("нормализованный Y")
        norm_y_neural = max(0, keras_model.predict(df_norm_x).item())

```



```
st.metric(label="price", value=f"{norm_y_neural:.4f}")

st.subheader("предсказанный Y")
pred_price_neural = scaler_y.inverse_transform([[norm_y_neural]]).item()
st.metric(label="price", value=f"${pred_price_neural:,.2f}")
```

max() – определяет наибольшее значение из двух, избавляется от отрицательных значений.

st.metric – отвечает за вывод результата прогнозируемого значения цены.

Линейная регрессия

$R^2=0.9163$

RMSE=797.49

предсказанный Y

price

\$2,225.73

Нейронная сеть

$R^2=0.974$

RMSE=0.0353

нормализованный Y

price

0.3620

предсказанный Y

price

\$4,511.72

Рисунок 6.4 - Результат части программы листинг 16

💎 Прогнозирование цены бриллианта

Характеристика алмаза

Караты

Качество огранки

Цвет ☐ J ☐ I ☐ H ☒ G ☐ F ☐ E ☐ D

Чистота

Глубина

Плоская грань

Длина

Высота

Ширина

исходные X

carat	cut	color	clarity	depth	table	x	y	z
1.10	Very Good	G	VS1	63.4	56.0	7.72	4.28	4.40

нормализованные X

carat	cut	color	clarity	depth	table	x	y	z
0.5	0.5	0.5	0.5714	0.7797	0.3478	0.8769	0.1307	0.7686

Линейная регрессия

$R^2=0.9163$

RMSE=797.49

предсказанный Y

price

\$2,225.73

Нейронная сеть

$R^2=0.974$

RMSE=0.0353

нормализованный Y

price

0.3620

предсказанный Y

price

\$4,511.72

Рисунок 6.5 – Web интерфейс

7 Проверка полученного результата

С помощью данных приведённых в таблицах 7.1 и 7.2 графически визуализируем полученные значения на рисунке 7.1.


Таблица 7.1 – Вводимые параметры

№	carat	cut	color	clarity	depth	table	price	x	y	z
1	0.24	Very good	J	VV2	62.8	57	336	3.94	3.96	2.48
2	1.68	Ideal	E	SI2	60.4	55	11888	7.79	7.7	4.68
3	0.44	Ideal	E	SI1	61.1	56	1040	4.92	4.9	3.0
4	0.7	Ideal	E	SI1	62.5	57	2757	5.7	5.72	.57
5	0.96	Premium	I	VS2	60.6	60	3876,0	6.4	6.47	3.9
6	1.16	Premium	I	VS2	62.2	58.0	4958	6.74	6.67	4.17
7	1.22	Premium	E	SI2	61.5	58	6121	6.86	6.84	4.21
8	1.32	Very Good	H	SI1	62.3	57	7270	7.04	6.99	4.37
9	1.5	Very Good	J	VVS2	63.3	57	8427	7.28	7.25	4.6
10	1.51	Good	I	VS1	63.6	57	9581	7.14	7.21	4.56

Таблица 7.2 – Сравнение результатов

№	Исходное значение цены	Цена от лин.регрессии	Цена от нейронной сети
1	336	0	326
2	1040	1012.21	1025.69
3	2757	2841.03	2681.95
4	3878	4251.54	4622.68
5	4958	5860.97	5640.77
6	6121	6687.42	5746.64
7	7270	7062.18	7231.42
8	8427	9274.19	8774.98
9	9581	9379.54	9465.55
10	11888	9485.56	8309.66

В результате полученных значений, по рисунку 7.1, спрогнозированные значения нейронной сети являются наиболее близкими к эталонным, при значениях цены более 9500 и на промежутке от 2700 до 5000 линейная регрессия показывает наиболее точное значение. Для более эффективного прогнозирования необходимо комбинировать работу моделей.



Рисуно 7.1 – Графическое отображение результатов

Заключение

В результате проделанной работы были выделены независимые признаки и целевая переменная, после чего выполнена нормализация методом MinMaxScaler и сформированы обучающая и тестовая выборки (train/test). Также реализованы две модели прогнозирования цены: линейная регрессия и нейронная сеть.

Для линейной регрессии получены показатели качества порядка $R^2 \approx 0.915$ и $RMSE \approx 798\$$, что подтверждает работоспособность линейного приближения. Для нейронной сети построена архитектура с двумя скрытыми слоями (64 и 32 нейрона, ReLU) и выходом из одного нейрона (linear), обучение выполнено на нормализованных данных с функцией потерь MSE и оптимизатором Adam; достигнуты метрики $R^2 \approx 0.972$ и $RMSE \approx 0.039$ в нормализованном виде, что демонстрирует более высокую точность по сравнению с линейной моделью.

Проверка работоспособности на наборе тестовых примеров показала, что в целом прогнозы нейронной сети чаще оказываются ближе к эталонным, однако в отдельных диапазонах значений линейная регрессия может давать сопоставимый или более точный результат, что обосновывает идею комбинирования моделей для повышения устойчивости прогноза.

Приложение А

Листинг программы сервисного модуля

```
import streamlit as st
import pickle
import numpy as np
import pandas as pd
from pandas import DataFrame
from tensorflow.keras.models import load_model

FOLDER = 'models/'

def init_models_and_scalers():
    if 'models_loaded' not in st.session_state:
        try:
            linear_model, keras_model, scaler_x, scaler_y =
load_models_and_scalers()
            st.session_state.update({
                'linear_model': linear_model,
                'keras_model': keras_model,
                'scaler_x': scaler_x,
                'scaler_y': scaler_y,
                'models_loaded': True
            })
            st.toast("✓ Модели и шкалёры успешно загружены.")
        except Exception as e:
            st.toast(f"✗ Ошибка загрузки: {e}")
            st.stop()

@st.cache_resource
def load_models_and_scalers():
    with open(FOLDER + 'linear_model.pkl', 'rb') as f:
        lin_model = pickle.load(f)

    ker_model = load_model(FOLDER + 'keras_model.h5', compile=False)

    with open(FOLDER + 'scaler_x.pkl', 'rb') as f:
        scal_x = pickle.load(f)

    with open(FOLDER + 'scaler_y.pkl', 'rb') as f:
        scal_y = pickle.load(f)

    return lin_model, ker_model, scal_x, scal_y

def get_prepared_df_x(df) -> DataFrame:
    df = df.copy()
    color_order = ['J', 'I', 'H', 'G', 'F', 'E', 'D']
    df['color'] = df['color'].map({v: i + 1 for i, v in enumerate(color_order)})

    cut_order = ['Fair', 'Good', 'Very Good', 'Premium', 'Ideal']
    df['cut'] = df['cut'].map({v: i + 1 for i, v in enumerate(cut_order)})

    clarity_order = ['I1', 'SI2', 'SI1', 'VS2', 'VS1', 'VVS2', 'VVS1', 'IF']
    df['clarity'] = df['clarity'].map({v: i + 1 for i, v in
enumerate(clarity_order)})
    return df
```

Приложение Б

Листинг программы модуля графического интерфейса

```
import streamlit as st
import pandas as pd
from sklearn.preprocessing import MinMaxScaler

import service

notification_shown = False

st.set_page_config(page_title="Прогнозирование цены бриллианта", layout="wide")
st.title("💎 Прогнозирование цены бриллианта")

service.init_models_and_scalers()

linear_model = st.session_state.linear_model
keras_model = st.session_state.keras_model
scaler_x:MinMaxScaler = st.session_state.scaler_x
scaler_y:MinMaxScaler = st.session_state.scaler_y

input_column, margin, output_column = st.columns([2, 0.25, 3])

with input_column:
    ### Входные данные
    st.header("Характеристика алмаза")

    carat = st.slider("Караты", min_value=0.2, max_value=2.0, value=1.1, step=0.01)
    cut = st.selectbox("Качество огранки", ["Fair", "Good", "Very Good", "Premium",
    "Ideal"], index=2)
    color = st.radio("Цвет", ['J', 'I', 'H', 'G', 'F', 'E', 'D'], index=3,
    horizontal=True)
    clarity = st.selectbox("Чистота", ['I1', 'SI2', 'SI1', 'VS2', 'VS1', 'VVS2',
    'VVS1', 'IF'], index=4)
    depth = st.slider("Глубина", min_value=58.8, max_value=64.7, value=61.8,
    step=0.1)
    table = st.slider("Плоская грань", min_value=52.0, max_value=63.5, value=57.8,
    step=0.1)
    x = st.slider("Длина", min_value=3.73, max_value=8.28, value=6.0, step=0.01)
    y = st.slider("Высота", min_value=3.68, max_value=8.27, value=5.98, step=0.01)
    z = st.slider("Ширина", min_value=1.41, max_value=5.3, value=3.36, step=0.01)

    ### Кнопка предсказания
    st.markdown("""
    <style>
        button[kind="primary"] {
            background: linear-gradient(135deg, #8b5cf6, #7c3aed);
            color: white;
            border-radius: 12px;
            padding: 16px 28px;
            font-size: 20px;
            font-weight: 600;
            box-shadow: 0 4px 14px rgba(139, 92, 246, 0.3);
        }
        button[kind="primary"]:hover {
            transform: translateY(-2px);
            box-shadow: 0 6px 20px rgba(139, 92, 246, 0.4);
        }
    </style>
    """)
```

```

"""", unsafe_allow_html=True)

clicked = st.button("Предсказать", type="primary", use_container_width=True)

with output_column:
    input_data = {
        'carat': [carat],
        'cut': [cut],
        'color': [color],
        'clarity': [clarity],
        'depth': [depth],
        'table': [table],
        'x': [x],
        'y': [y],
        'z': [z]
    }

    ### Таблица исходных X
    st.markdown(
        "<h2 style='text-align: center; color: #2d3748; font-size: 30px';>исходные X</h2>",
        unsafe_allow_html=True
    )
    df_raw_x = pd.DataFrame(input_data)
    st.dataframe(
        df_raw_x,
        hide_index=True,
        use_container_width=True,
        column_config={
            "carat": st.column_config.NumberColumn("carat", format="%.2f"),
            "depth": st.column_config.NumberColumn("depth", format="%.1f"),
            "table": st.column_config.NumberColumn("table", format="%.1f"),
            "x": st.column_config.NumberColumn("x", format="%.2f"),
            "y": st.column_config.NumberColumn("y", format="%.2f"),
            "z": st.column_config.NumberColumn("z", format="%.2f"),
        }
    )

    ### Таблица нормализованных X
    df_x = service.get_prepared_df_x(df_raw_x)
    st.markdown(
        "<h2 style='text-align: center; color: #2d3748; font-size: 30px';>нормализованные X</h2>",
        unsafe_allow_html=True
    )
    columns = ['carat', 'cut', 'color', 'clarity', 'depth', 'table', 'x', 'y', 'z']
    df_norm_x = pd.DataFrame(data = scaler_x.transform(df_x), columns =
df_x.columns, index = df_x.index)
    st.dataframe(df_norm_x, hide_index=True, use_container_width=True)

    col_linear, col_neural = st.columns(2)

    if clicked:
        with col_linear:
            st.header("Линейная регрессия")
            st.write("**R²=0.9163**")
            st.write("**RMSE=797.49**")

            st.subheader("предсказанный Y")
            pred_price_linear = max(0, linear_model.predict(df_x).item())

```

```

        st.metric(label="price", value=f"${pred_price_linear:,.2f}")

    with col_neural:
        st.header("Нейронная сеть")
        st.write("**R2=0.974**")
        st.write("**RMSE=0.0353**")

        st.subheader("нормализованный Y")
        norm_y_neural = max(0, keras_model.predict(df_norm_x).item())
        st.metric(label="price", value=f"${norm_y_neural:.4f}")

        st.subheader("предсказанный Y")
        pred_price_neural =
scaler_y.inverse_transform([[norm_y_neural]]).item()
        st.metric(label="price", value=f"${pred_price_neural:,.2f}")

st.markdown("---")

```