

# Ансамблирование моделей нейронных сетей с использованием библиотеки Keras

Еще один метод улучшения результатов в решении задач — ансамблирование моделей. Суть метода ансамблирования заключается в объединении прогнозов, полученных набором разных моделей, для получения лучшего прогноза.

Ансамблирование основано на предположении о том, что разные хорошие модели, обученные независимо, могут быть хороши по разным причинам: каждая модель рассматривает немного другие аспекты данных, чтобы сделать прогноз, и видит только часть «истины».

Возьмем в качестве примера задачу классификации. Самый простой способ объединить прогнозы из множества классификаторов (ансамблировать классификаторы) — получить среднее их прогнозов на этапе вывода:

```
preds_a = model_a.predict(x_val)
preds_b = model_b.predict(x_val)
preds_c = model_c.predict(x_val)
preds_d = model_d.predict(x_val)
final_preds = 0.25 * (preds_a + preds_b + preds_c + preds_d)
```

Этот прием даст положительные результаты, только если исходные классификаторы примерно одинаково хороши. Если один будет значительно хуже других, окончательный прогноз может получиться хуже прогноза лучшего классификатора в группе. Более эффективный способ ансамблирования классификаторов — вычисление взвешенного среднего с определением весов по проверочным данным, когда лучший классификатор получает больший вес, а худший — меньший. Для поиска оптимальных весов в ансамбле можно использовать алгоритм случайного поиска или простой оптимизации, такой как Nelder-Mead:

```
preds_a = model_a.predict(x_val)
preds_b = model_b.predict(x_val)
preds_c = model_c.predict(x_val)
preds_d = model_d.predict(x_val)
final_preds = 0.5 * preds_a + 0.25 * preds_b + 0.1 * preds_c + 0.15 * preds_d
```

Существует много возможных вариантов: вы можете вычислить среднее экспоненциальное прогнозов, for instance. В общем случае простое взвешенное среднее с весами, оптимизированными на проверочных данных, может служить очень неплохим базовым решением. Ключом к достижению успеха в результате ансамблирования является разнообразие набора классификаторов.

Разнообразие — вот что обеспечивает успех ансамблирования. Выражаясь языком машинного обучения: если все ваши модели будут одинаково предвзятыми, ваш ансамбль сохранит эту предвзятость. Если ваши модели будут предвзяты по-разному, предвзятости будут нивелировать друг друга, и ансамбль получится более точным и надежным.

По этой причине объединяться в ансамбли должны максимально хорошие и разные модели. Это обычно означает использование разных архитектур или даже разных подходов к машинному обучению. Единственное, пожалуй, чего не следует делать — ансамблировать ту же сеть, обученную несколько раз, даже при разных начальных случайных значениях. Если ваши модели различаются только начальными значениями и тем, в каком порядке они обрабатывали обучающие данные, ваш ансамбль будет иметь низкое разнообразие и обеспечит лишь незначительное улучшение по сравнению с единственной моделью.