

Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Новосибирский государственный технический университет»

Кафедра Вычислительной техники

ОТЧЕТ ПО ПРАКТИКЕ

Производственная практика: научно-исследовательская работа

Направление подготовки, профиль: 09.04.04 Программная инженерия. Автономные интеллектуальные системы

Выполнил:

Студент: Клименко К. В.
(Ф.И.О.)

Группа: АПИМ-25

Факультет: АВТФ

подпись

«___» _____ 2026 г.

Проверил:

Руководитель от НГТУ: Алейников А. Ф.
(Ф.И.О.)

Балл: _____, ECTS _____,

Оценка: «отлично»

подпись

«___» _____ 2026 г.

Новосибирск 2026

Оглавление

Введение	3
Цель исследования	4
Основная часть	4
1. Обоснование архитектуры и необходимости многоэтапной сегментации	4
2. Архитектура и реализация моделей сегментации	7
3. Формирование датасетов и подготовка данных	10
4. Экспериментальные исследования и оптимизация	12
Вывод	14
Список использованной литературы	15

Введение

Разработка систем автоматизированной диагностики заболеваний растений на основе компьютерного зрения является актуальной задачей современного прецизионного земледелия. Внедрение мобильных решений для мониторинга состояния посевов позволяет оперативно выявлять патологии и оптимизировать использование агрохимикатов. Однако ключевой проблемой при переносе алгоритмов из лабораторных условий в реальную среду является сильная зависимость моделей от фона, освещения и ракурса съемки, что приводит к резкому падению точности классификации.

В этом контексте построение надежного пайплайна требует не просто распознавания типа заболевания, но и предварительной точной локализации объекта интереса. Первым критическим этапом является разработка модуля семантической сегментации листовых пластин. Изоляция листа от сложного фона (почва, другие растения) позволяет устранить шумовые артефакты и сфокусировать вычислительные ресурсы модели исключительно на биоморфологических признаках растения, что математически обосновано снижением дисперсии внутриклассовых признаков.

Наконец, ключевым аспектом работы является разработка модели сегментации локальных поражений (пятен, некрозов, хлорозов). Эта задача осложняется экстремальным дисбалансом классов, так как площадь пятен часто составляет менее 1–5% от площади листа. Для решения этой проблемы требуется подбор специализированных функций потерь, устойчивых к дисбалансу, и оптимизация гиперпараметров для выявления мелких объектов.

Таким образом, цель данной практики — разработка и экспериментальное исследование алгоритмов семантической сегментации для системы автоматизированной диагностики заболеваний растений. В ходе работы будут решены задачи выбора архитектуры нейросетей, формирования синтетических и реальных датасетов, а также оптимизации функций потерь для достижения метрик качества, достаточных для интеграции в мобильное приложение.

Цель исследования

Целью проектно-технологической практики является разработка и экспериментальное исследование алгоритмов семантической сегментации для системы автоматизированной диагностики заболеваний растений, включающее обоснование архитектуры нейросетевых моделей, формирование синтетических и реальных датасетов, а также оптимизацию функций потерь для достижения метрик качества, достаточных для интеграции в мобильное приложение.

Основная часть

1. Обоснование архитектуры и необходимости многоэтапной сегментации

Первоначальным этапом исследования стала разработка и оценка эффективности модели прямой классификации заболеваний листьев. В качестве базовой архитектуры был выбран сверточный нейросетевой энкодер MobileNetV3Large [7]. Данный выбор обусловлен оптимальным балансом между вычислительной сложностью и точностью распознавания: архитектура MobileNetV3 демонстрирует лучшую производительность на мобильных устройствах по сравнению с более тяжелыми аналогами (например, EfficientNet или классическим ResNet), сохраняя при этом высокую емкость признакового пространства благодаря использованию механизмов внимания (Squeeze-and-Excitation blocks) и нелинейных функций активации h-swish.

Для обучения модели использовался датасет PlantVillage [8], являющийся одним из наиболее репрезентативных открытых источников в области фитопатологии. Датасет содержит 54 306 изображений, охватывающих 38 классов. Ключевой особенностью данного датасета является то, что изображения были получены в контролируемых лабораторных условиях на однородном фоне.

Гипотеза исследования заключалась в том, что наличие неоднородного фона (почва, другие листья, тени) в реальных условиях эксплуатации мобильного приложения существенно снизит точность классификатора. Чтобы количественно оценить влияние фона, был проведен сравнительный эксперимент с искусственной изоляцией объекта интереса (ROI).

Для имитации идеальной сегментации была разработана процедура бинаризации фона. Поскольку исходные изображения PlantVillage имеют однородный светлый фон, применение простого порогового преобразования позволило эффективно отделить лист от фона.

Было проведено две серии экспериментов:

1. **Full-frame**: Обучение на исходных изображениях с лабораторным фоном.
2. **Masked**: Обучение на изображениях, где фон заменен на черный (нулевые значения пикселей).

Для приведения датасета в соответствие с архитектурой финального пайплайна, требующего наличия пар «здоровое/больное» растение для каждого вида культуры, из набора данных были исключены классы, не имеющие пары (только здоровые или только больные классы). Итоговый набор составил 33 класса. Результаты обучения модели для 33 релевантных классов представлены в Таблице 1.

Параметр	Full-frame (Лабораторный фон)	Masked (Черный фон / Имитация сегментации)
Accuracy (Val)	0.9686	0.9706
F1-Score (Val)	0.9648	0.9660
Loss (Val)	0.2644	0.2085
Время обучения	40 мин 11 сек	35 мин 38 сек

Таблица 1. Сравнительные метрики для 33 классов (отфильтрованный датасет)

Как видно из результатов, использование маскированного фона критически снизило функцию потерь (Loss) с 0.2644 до 0.2085, а также ускорило сходимость модели более чем на 4 минуты.

Улучшение метрик при использовании маскированного фона можно объяснить с точки зрения статистики признаков, извлекаемых сверточными слоями. Пусть I — входное изображение, представляющее собой сумму сигнала от объекта интереса (листа) S_{leaf} и сигнала фона S_{bg} , а также аддитивного шума ϵ :

$$I(x, y) = S_{leaf}(x, y) + S_{bg}(x, y) + \epsilon(x, y)$$

При обучении классификатора на full-frame изображениях, сверточные фильтры K вычисляют отклик R как свертку ($*$ - операция свертки):

$$R = I * K = (S_{leaf} * K) + (S_{bg} * K) + (\epsilon * K)$$

В случае с PlantVillage фон однороден, однако его спектральные характеристики могут коррелировать с определенными фильтрами нижних уровней, создавая ложные признаки. Модель может научиться классифицировать заболевание не по текстуре пятна, а по микро-вариациям освещения на белом фоне.

Использование сегментации (или её имитации через маску $M(x, y) = 1$ для листа и 0 для фона) позволяет аннулировать вклад фона:

$$I_{segm}(x, y) = I(x, y) \cdot M(x, y) \approx S_{leaf}(x, y)$$

Таким образом, отклик сети становится зависимым исключительно от биоморфологических признаков растения. Это приводит к снижению дисперсии внутриклассовых признаков и увеличению межклассового расстояния в пространстве эмбедингов. Снижение Loss на ~25% свидетельствует о том, что модель без сегментации тратит значительные ресурсы на игнорирование фона.

Проведенные эксперименты доказывают, что изоляция объекта интереса является критически важным этапом. В реальных условиях фон является неоднородным и динамичным, поэтому простое пороговое преобразование неприменимо. Следовательно, перед блоком классификации необходимо внедрить модуль семантической сегментации, выполняющий роль адаптивного фильтра.

2. Архитектура и реализация моделей сегментации

Семантическая сегментация — это задача классификации каждого пикселя изображения в определенный класс. В контексте данной работы выделяются два основных класса объектов: «лист растения» (foreground) и «фон» (background).

На текущий момент в компьютерном зрении доминируют три основных семейства архитектур для сегментации:

1. **FCN (Fully Convolutional Networks):** пионерские модели, заменившие полносвязные слои на сверточные, что позволило работать с изображениями произвольного размера [2]. Однако они часто теряют пространственную информацию из-за агрессивного пулинга.
2. **DeepLab:** используют атрус-свертки и механизм Atrous Spatial Pyramid Pooling (ASPP) для захвата контекста на разных масштабах без потери разрешения. Эти модели обеспечивают высокую точность, но требуют значительных вычислительных ресурсов.
3. **U-Net и его модификации:** архитектура encoder-decoder с симметричными связями пропуска (skip-connections). Изначально разработанная для биомедицинской сегментации, U-Net показала исключительную эффективность на задачах с ограниченными данными и необходимостью точной локализации границ объектов [4].

Исходя из этих требований, архитектура **U-Net [4]** была выбрана как базовая, поскольку она обеспечивает оптимальный баланс между сохранением высокочастотных деталей (через skip-connections) и глубиной семантического понимания (через энкодер).

Классический U-Net использует простой сверточный энкодер. Для улучшения качества извлечения признаков было принято решение заменить стандартный энкодер на предобученную сеть **MobileNetV3Large [7]**. Это позволяет использовать веса, обученные на ImageNet, для инициализации низкоуровневых фильтров.

Предложенная модель представляет собой асимметричный U-Net, где:

1. **Энкодер:** MobileNetV3Large (без классификационной головы).
2. **Декодер:** Кастомная сеть повышающей дискретизации (upsampling) с конкатенацией.

Главной инженерной задачей была корректная организация skip-connections. Был проведен детальный анализ графа вычислений модели. В качестве точек выхода были выбраны слои, обеспечивающие пирамиду признаков с шагом downsampling 2^k :

Уровень U-Net	Имя слоя в MobileNetV3	Разрешение (при входе 256x256)	Описание блока
Skip 1	expanded_conv_add	128×128	Выход первого residual блока
Skip 2	expanded_conv_2_add	64×64	Выход второго блока
Skip 3	expanded_conv_5_add	32×32	Выход пятого блока
Skip 4	expanded_conv_11_add	16×16	Глубокие семантические признаки

Таблица 2. Уровни skip-connections в MobileNetV3




Рисунок 1. Схема архитектуры сегментационной модели на базе гибридной структуры MobileNetV3 + U-Net: 1–4 — уровни энкодера (MobileNetV3), извлекающие признаки на масштабах 128×128, 64×64, 32×32, 16×16 соответственно; 5–8 — уровни декодера с апсемплингом и конкатенацией со соответствующими уровнями энкодера

Декодер состоит из четырех последовательных блоков upsample_block. Каждый блок выполняет следующие операции:

1. Повышение разрешения через билинейную интерполяцию (UpSampling2D).
2. Конкатенация с картой признаков из энкодера.
3. Сверточная обработка (Conv2D 3×3, ReLU, BatchNormalization).

Математически операция в блоке upsampling для уровня i может быть описана как:

$$D_i = \text{Conv}_{3 \times 3} \left(\text{BN} \left(\text{Concat} \left(\text{UpSample}(D_{i+1}), E_i \right) \right) \right)$$

где:

- D_{i+1} — карта признаков с предыдущего (более глубокого) уровня декодера.
- E_i — карта признаков с i -го уровня энкодера (MobileNet).

- UpSample — операция билинейной интерполяции.

Для обеспечения гибкости кодовой базы процесс сборки модели был реализован через унифицированный метод `create_segmentation_model`, управляемый флагом `is_leaf_seg` (Листинг 1).

```
def create_segmentation_model(deep_model, is_leaf_seg: bool,
                             learning_rate: float = 0.001) -> Model:
    layer_names = [
        'expanded_conv_add', # 128×128
        'expanded_conv_2_add', # 64×64
        'expanded_conv_5_add', # 32×32
        'expanded_conv_11_add', # 16×16
    ]
    skip_connections = [deep_model.get_layer(name).output for name in layer_names]

    x = deep_model.output
    x = upsample_block(x, skip_connections[3], 256) # 16×16
    x = upsample_block(x, skip_connections[2], 128) # 32×32
    x = upsample_block(x, skip_connections[1], 64) # 64×64
    x = upsample_block(x, skip_connections[0], 32) # 128×128

    x = UpSampling2D(size=(2, 2), interpolation='bilinear')(x)
    x = Conv2D(32, 3, padding='same', activation='relu')(x)
    x = BatchNormalization()(x)
    x = Dropout(0.2)(x)
    prediction = Conv2D(1, 1, activation='sigmoid')(x)
    model = Model(inputs=deep_model.input, outputs=prediction)
    model.compile(
        optimizer=Adam(learning_rate=learning_rate),
        loss=bce_dice_loss if is_leaf_seg else tversky_loss,
        metrics=[
            BinaryIoU(target_class_ids=[1], threshold=0.5, name='iou'),
            dice_coef]
    )
    return model

def upsample_block(x, skip, filters):
    x = UpSampling2D(size=(2, 2), interpolation='bilinear')(x)
    x = Concatenate()([x, skip])
    x = Conv2D(filters, 3, padding='same', activation='relu')(x)
    x = BatchNormalization()(x)
    x = Dropout(0.1)(x)
    return x
```

Листинг 1. Код архитектуры сегментационной модели (deep_model – encoder)

3. Формирование датасетов и подготовка данных

3.1. Формирование синтетического датасета для сегментации листьев

Одной из ключевых проблем является дефицит размеченных данных для сегментации листьев. Для решения этой проблемы была разработана стратегия создания крупномасштабного синтетического датасета.

Алгоритм синтеза:

1. **Источник:** 7600 изображений листьев из PlantVillage.
2. **Генерация масок:** Автоматическая пороговая бинаризация (Threshold=5) с морфологической очисткой.
3. **Библиотека фонов:** 300 реалистичных изображений (почва, трава, руки, ткани).
4. **Композиция:** Альфа-смешивание листа и фона по маске:

$$I_{comp} = I_{leaf} \cdot M + I_{bg} \cdot (1 - M), \text{ где}$$

- I_{leaf} — изображение листа (RGB).
- I_{bg} — изображение фона (RGB), масштабированное под размер листа.
- M — бинарная маска, нормализованная к диапазону $[0,1]$.
- I_{comp} — итоговое синтезированное изображение.

Итоговый синтетический датасет составил 7000 изображений, использованных для первичного обучения (pre-training).

3.2. Подготовка датасета для сегментации поражений

Для задачи выделения локальных поражений требуется реальные изображения с точными аннотациями. Был использован датасет PlantSeg [9], содержащий 7916 пар «изображение – маска» в полевых условиях. Был проведен ручной аудит всех 7916 изображений. Удалены фотографии плодов и кадры низкого качества. Итоговый объем «чистого» датасета составил 4581 пару.

Для увеличения объема выборки применена агрессивная аугментация (коэффициент 2) с использованием библиотеки Albumentations [1]. Используются синхронные геометрические трансформации (повороты, отражения) и цветовые искажения. Итоговый объем датасета увеличен до 13 743 изображений. Все изображения для модели spot_seg были пропущены через ранее обученный сегментатор листьев leaf_seg для удаления фона. Фон заменялся на черный цвет, что имитирует идеальную сегментацию и устраняет шум.




Рисунок 2. Слева — исходное фото с сложным фоном; По центру — результат работы первого сегментатора (лист вырезан); Справа — маска поражений на черном фоне.

Для обеспечения высокой производительности обучения был реализован собственный пайплайн на базе `tf.data.Dataset` (Листинг 2), поддерживающий параллельную загрузку и синхронный ресайзинг.

```
def get_segmentation_train_val_datasets(images_dir: str,
                                       masks_dir: str,
                                       preprocess_input_function,
                                       image_size: tuple,
                                       batch_size: int,
                                       validation_split: float):
    # ... (код сортировки и разделения путей) ...

    train_dataset = tf.data.Dataset.from_tensor_slices((train_img, train_mask))
    val_dataset = tf.data.Dataset.from_tensor_slices((val_img, val_mask))

    train_dataset = train_dataset.map(
        lambda image_path, mask_path: (
            load_image(image_path, image_size, preprocess_input_function),
            load_mask(mask_path, image_size)),
        num_parallel_calls=tf.data.AUTOTUNE)

    val_dataset = val_dataset.map(
        lambda image_path, mask_path: (
            load_image(image_path, image_size, preprocess_input_function),
            load_mask(mask_path, image_size)),
        num_parallel_calls=tf.data.AUTOTUNE)

    train_dataset = train_dataset.shuffle(buffer_size=1000)
    train_dataset = train_dataset.batch(batch_size).prefetch(tf.data.AUTOTUNE)
    val_dataset = val_dataset.batch(batch_size).prefetch(tf.data.AUTOTUNE)

    return train_dataset, val_dataset
```

Листинг 4. Функция загрузки датасета для сегментации

4. Экспериментальные исследования и оптимизация

4.1. Обучение модели сегментации листьев (Leaf_Seg)

Первоначальное обучение на синтетике с использованием Binary Cross-Entropy (BCE) показало Val IoU = 0.9870. Однако чистая BCE имеет недостатки при размытых границах.

Для решения этой проблемы была внедрена комбинированная функция потерь BCE + Dice Loss [6]. Dice Loss является глобальной метрикой, напрямую оптимизирующей площадь пересечения, что эффективно при дисбалансе классов.

Модель	Функция потерь	Dropout	Val IoU	Val Loss
Baseline	BCE	Нет	0.9870	0.0113
Optimized	BCE + Dice	Да	0.9954	0.0052

Таблица 3. Сравнение эффективности функций потерь на синтетическом датасете

Несмотря на высокий IoU на синтетике, тестирование на реальных фото выявило падение качества. Для адаптации была применена стратегия Active Learning. Отобрано 111 критических кейсов с ошибками, вручную скорректированы маски. Итоговый набор для Fine-tuning составил 780 изображений. Дообучение с низким Learning Rate ($1e-5$) позволило достичь Test IoU = 0.8734 на независимом тестовом наборе реальных изображений.

4.2. Обучение модели сегментации поражений (Spot_Seg)

Задача сегментации пятен осложняется экстремальным дисбалансом классов (площадь пятен $<1-5\%$). Обучение с BCE и Batch Size 128 провалилось (Val IoU = 0.6635) из-за игнорирования моделью мелких объектов. Модель быстро научилась предсказывать «фон», минимизируя глобальную ошибку.

Для решения проблемы дисбаланса использована Tversky Loss [5] с параметрами $\alpha=0.7, \beta=0.3$. Это сместило фокус на минимизацию False Negatives (пропуск пятен):

Функция потерь Tversky определяется следующим образом:

$$L_{\text{Tversky}} = 1 - \frac{TP}{TP + \alpha \cdot FN + \beta \cdot FP}, \text{ где:}$$

- TP (True Positives) — верно предсказанные пиксели пятна.
- FN (False Negatives) — пропущенные пиксели пятна.

- *FP* (False Positives) – ложно определенные пиксели фона как пятна.
- α и β — весовые коэффициенты, контролирующие важность FN и FP соответственно.

Снижение Batch Size со 128 до 32 увеличило частоту обновлений весов и сделало градиент более чувствительным к редким признакам пятен, которые «размывались» при усреднении в больших батчах.

Конфигурация	Функция потерь	Размер батча	Валидационный IoU	Примечание
Baseline	BCE	128	0.6635	Early Stopping на эпохе 10
Optimized	Tversky ($\alpha=0.7$)	32	0.7823	Полное обучение (30 эпох)

Таблица 4. Сравнение результатов базовой и оптимизированной конфигураций

Финальная оценка модели *spot_seg* на независимом тестовом наборе показала Test IoU = 0.7923. Полученное значение является высоким для задачи сегментации мелких объектов в полевых условиях. Визуальный анализ подтвердил способность модели выделять как крупные некрозы, так и микроскопические точечные поражения (менее 1% площади листа).

Разработанный пайплайн, состоящий из последовательной работы моделей *leaf_seg* (IoU 0.87) и *spot_seg* (IoU 0.79), позволяет объективно рассчитывать степень поражения растения $S = \frac{A_{lesion}}{A_{leaf}}$, что закрывает критический пробел между классификацией типа болезни и количественной оценкой ущерба.

Вывод

В ходе выполнения индивидуального задания по производственной практике были разработаны и исследованы алгоритмы семантической сегментации для системы автоматизированной диагностики заболеваний растений. Проведен сравнительный анализ архитектур нейронных сетей, в результате которого для задач выделения листовых пластин и локальных поражений была выбрана гибридная модель на базе U-Net с энкодером MobileNetV3Large. Данный выбор обеспечил оптимальный баланс между точностью локализации границ объектов и вычислительной эффективностью, что является критическим требованием для последующей интеграции моделей в мобильное приложение.

В процессе экспериментальных исследований решены ключевые проблемы компьютерного зрения в агрономии: дефицит размеченных данных и экстремальный дисбаланс классов. Для сегментации листьев применена стратегия генерации крупномасштабного синтетического датасета (7000 изображений) с последующим дообучением на реальных данных методом активного обучения, что позволило достичь метрики $\text{IoU} = 0.8734$ в сложных полевых условиях. Для сегментации мелких поражений, занимающих менее 5% площади изображения, оптимизирована функция потерь (переход на Tversky Loss с $\alpha=0.7$) и размер батча, что обеспечило рост метрики IoU с 0.66 до 0.7923 и гарантировало надежное выявление микроскопических симптомов болезней.

Таким образом, целью практики достигнута: создан полнофункциональный пайплайн обработки изображений, состоящий из последовательно работающих модулей `leaf_seg` и `spot_seg`. Разработанные алгоритмы позволяют объективно рассчитывать степень поражения растения $S=S_{\text{spot}}/S_{\text{leaf}}$, закрывая пробел между качественной классификацией типа болезни и количественной оценкой ущерба. Полученные результаты демонстрируют высокую робастность моделей к изменению освещения, сложному фону и морфологическому разнообразию симптомов, что подтверждает их готовность к практическому применению в системах прецизионного земледелия.

Список использованной литературы

1. Buslaev A., Iglovikov V. I., Khvedchenya E. et al. Albumentations: Fast and Flexible Image Augmentations // Information. – 2020. – Vol. 11, № 2. – Article 125. – URL: <https://www.mdpi.com/2078-2489/11/2/125> (дата обращения: 11.04.2026).
2. Long J., Shelhamer E., Darrell T. Fully Convolutional Networks for Semantic Segmentation // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). – 2015. – P. 3431-3440. – URL: https://openaccess.thecvf.com/content_cvpr_2015/papers/Long_Fully_Convolutional_Networks_2015_CVPR_paper.pdf (дата обращения: 10.04.2026).
3. Peterson R. F., Campbell A. B., Hannah A. E. A Diagrammatic Scale for Estimating Rust Intensity on Leaves and Stems of Cereals // Canadian Journal of Research. – 1948. – Vol. 26C, № 5. – P. 496–500. – URL: <https://cdnsiencepub.com/doi/10.1139/cjr48c-033> (дата обращения: 11.04.2026).
4. Ronneberger O., Fischer P., Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation // International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI). – Springer, Cham, 2015. – P. 234-241. – URL: <https://arxiv.org/abs/1505.04597> (дата обращения: 10.04.2026).
5. Salehi S. S. M., Erdogmus D., Gholipour A. Tversky Loss Function for Image Segmentation Using 3D Fully Convolutional Deep Networks // Machine Learning in Medical Imaging (MLMI). – Springer, Cham, 2017. – Vol. 10541. – P. 379–387. – URL: <https://arxiv.org/abs/1706.05721> (дата обращения: 11.04.2026).
6. Sudre C. H., Li W., Vercauteren T. et al. Generalised Dice Loss as a Continuous Function for Class Imbalance in Medical Image Segmentation // Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support. – Springer, Cham, 2017. – P. 234-242. – URL: <https://arxiv.org/abs/1707.03237> (дата обращения: 10.04.2026).
7. Howard A., Sandler M., Chu G. et al. Searching for MobileNetV3 // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). – 2019. – P. 1314-1324. – URL: <https://arxiv.org/abs/1905.02244> (дата обращения: 10.04.2026).
8. Hughes D. P., Salathé M. An open access repository of images on plant health to enable the development of mobile disease diagnostics // arXiv preprint arXiv:1511.08060. – 2015. – URL: <https://arxiv.org/abs/1511.08060> (дата обращения: 10.04.2026).
9. Wei T., Chen Z., Yu X. et al. PlantSeg: A Large-Scale In-the-wild Dataset for Plant Disease Segmentation // Scientific Data. – 2025. – URL: <https://www.nature.com/articles/s41597-025-06513-4> (дата обращения: 11.04.2026).